

# تقرير تحليل بيانات سرطان الثدي في ويسكونسن (الأصلي)

## 1. المقدمة

يهدف هذا التقرير إلى تقديم تحليل شامل لمجموعة بيانات سرطان الثدي في ويسكونسن (الأصلي)، والتي تم التبرع بها في 14 يوليو 1992، وهي متاحة في مستودع UCI للتعليم الآلي [1]. تُستخدم هذه المجموعة على نطاق واسع في مهام التصنيف لتمييز الأورام الحميدة (Benign) عن الأورام الخبيثة (Malignant) بناءً على خصائص الخلايا المأخوذة من عينات خزعة.

## 2. نظرة عامة على مجموعة البيانات

تُصنف مجموعة البيانات هذه على أنها متعددة المتغيرات (Multivariate) وتندرج تحت مجال الصحة والطب. تتكون من 699 حالة (Instances) و 9 ميزات (Features) بالإضافة إلى عمود التصنيف (Class). نوع الميزات هو عدد صحيح (Integer).

خصائص المتغيرات:

| اسم المتغير                 | الدور | النوع    | الوصف                                    | القيم المفقودة |
|-----------------------------|-------|----------|------------------------------------------|----------------|
| Sample code number          | معرف  | فئوي     | رقم تعريف العينة                         | لا             |
| Clump Thickness             | ميزة  | عدد صحيح | 10 - 1                                   | لا             |
| Uniformity of Cell Size     | ميزة  | عدد صحيح | 10 - 1                                   | لا             |
| Uniformity of Cell Shape    | ميزة  | عدد صحيح | 10 - 1                                   | لا             |
| Marginal Adhesion           | ميزة  | عدد صحيح | 10 - 1                                   | لا             |
| Single Epithelial Cell Size | ميزة  | عدد صحيح | 10 - 1                                   | لا             |
| Bare Nuclei                 | ميزة  | عدد صحيح | 10 - 1                                   | نعم            |
| Bland Chromatin             | ميزة  | عدد صحيح | 10 - 1                                   | لا             |
| Normal Nucleoli             | ميزة  | عدد صحيح | 10 - 1                                   | لا             |
| Mitoses                     | ميزة  | عدد صحيح | 10 - 1                                   | لا             |
| Class                       | تصنيف | عدد صحيح | 2 للحميد (Benign) ، 4 للخبيث (Malignant) | لا             |

تُظهر مجموعة البيانات وجود قيم مفقودة في عمود Bare Nuclei ، والتي تم التعامل معها مسبقًا في الملف المرفق حيث لا توجد قيم مفقودة ظاهرة بعد تحميل البيانات.

### 3. استكشاف البيانات وتحليلها


بعد تحميل البيانات، تم إجراء تحليل استكشافي لفهم بنية البيانات وتوزيعها. تتكون مجموعة البيانات من 683 صفًا و 11 عمودًا. جميع الأعمدة من نوع int64 .

### الإحصائيات الوصفية للميزات العددية:

| الميزة                      | العدد | المتوسط | الانحراف المعياري | الحد الأدنى | الربع الأول (25%) | الوسيط (50%) | الربع الثالث (75%) | الحد الأقصى |
|-----------------------------|-------|---------|-------------------|-------------|-------------------|--------------|--------------------|-------------|
| Clump Thickness             | 683   | 4.44    | 2.82              | 1.00        | 2.00              | 4.00         | 6.00               | 10.00       |
| Uniformity of Cell Size     | 683   | 3.15    | 3.07              | 1.00        | 1.00              | 1.00         | 5.00               | 10.00       |
| Uniformity of Cell Shape    | 683   | 3.22    | 2.99              | 1.00        | 1.00              | 1.00         | 5.00               | 10.00       |
| Marginal Adhesion           | 683   | 2.83    | 2.86              | 1.00        | 1.00              | 1.00         | 4.00               | 10.00       |
| Single Epithelial Cell Size | 683   | 3.23    | 2.22              | 1.00        | 2.00              | 2.00         | 4.00               | 10.00       |
| Bare Nuclei                 | 683   | 3.54    | 3.64              | 1.00        | 1.00              | 1.00         | 6.00               | 10.00       |
| Bland Chromatin             | 683   | 3.45    | 2.45              | 1.00        | 2.00              | 3.00         | 5.00               | 10.00       |
| Normal Nucleoli             | 683   | 2.87    | 3.05              | 1.00        | 1.00              | 1.00         | 4.00               | 10.00       |
| Mitoses                     | 683   | 1.60    | 1.73              | 1.00        | 1.00              | 1.00         | 1.00               | 10.00       |

### 3.1. توزيع فئات سرطان الثدي

يُظهر تحليل توزيع فئات سرطان الثدي أن غالبية العينات حميدة. من إجمالي 683 عينة، هناك 444 عينة حميدة (حوالي 65%) و 239 عينة خبيثة (حوالي 35%). هذا التوزيع يشير إلى وجود عدم توازن في فئات البيانات، وهو أمر يجب أخذه في الاعتبار عند بناء نماذج التعلم الآلي.



### 3.2. مصفوفة الارتباط بين الميزات

تُظهر خريطة الحرارة للارتباط (Correlation Heatmap) العلاقات بين الميزات المختلفة وفئة التصنيف. الملاحظات الرئيسية هي:

- هناك ارتباطات إيجابية قوية بين معظم الميزات الخلوية (مثل `Clump Thickness`, `Uniformity of Cell Size`, `Uniformity of Cell Shape`, `Bare Nuclei`, `Bland Chromatin`, `Normal Nucleoli`) وبين فئة التصنيف (`Class`). هذا يشير إلى أن هذه الميزات مهمة في التمييز بين الأورام الحميدة والخبيثة.
- أعلى الارتباطات مع `Class` هي `Uniformity of Cell Size` (0.82) و `Uniformity of Cell Shape` (0.82). `Bare Nuclei` (0.82)، مما يؤكد أهميتها في التنبؤ.
- ميزة `Mitoses` لديها أقل ارتباط مع `Class` (0.42) مقارنة بالميزات الأخرى.

### 3.3. سمك التكتل حسب الفئة

يُظهر مخطط الصندوق (`Box Plot`) لـ `Clump Thickness` (سمك التكتل) حسب فئة التصنيف أن الأورام الخبيثة تميل إلى أن يكون لها سمك تكتل أعلى بكثير من الأورام الحميدة. تتراوح قيم سمك التكتل للأورام الحميدة بشكل أساسي بين 1 و 4، بينما تتراوح للأورام الخبيثة بين 5 و 10.

### 3.4. تجانس حجم وشكل الخلية

يُظهر مخطط التشتت (Scatter Plot) العلاقة بين Uniformity of Cell Size (تجانس حجم الخلية) و Uniformity of Cell Shape (تجانس شكل الخلية). يمكن ملاحظة أن العينات الحميدة (Class 2) تميل إلى التجمع في الجزء السفلي الأيسر من الرسم البياني، حيث تكون قيم تجانس حجم وشكل الخلية منخفضة (عادةً 1-3). في المقابل، تنتشر العينات الخبيثة (Class 4) عبر نطاق أوسع من القيم، وتميل إلى أن تكون لها قيم أعلى في كلتا الميزتين، مما يشير إلى عدم تجانس أكبر في حجم وشكل الخلايا.

## 4. الخلاصة

تُعد مجموعة بيانات سرطان الثدي في ويسكونسن موردًا قيمًا لتطوير نماذج تصنيف الأورام. يُظهر التحليل الاستكشافي أن هناك علاقات قوية بين الخصائص الخلوية المختلفة وفئة الورم (حميد/خبيث). الميزات مثل Uniformity of Cell Size و Uniformity of Cell Shape و Bare Nuclei هي الأكثر ارتباطًا بفئة التصنيف، مما يجعلها مرشحات قوية للميزات في نماذج التعلم الآلي. يجب معالجة عدم توازن الفئات في البيانات لضمان أداء قوي للنموذج.

## 5. المراجع

[1] Wolberg, W. (1990). Breast Cancer Wisconsin (Original) [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5HP4Z>